

# 基于 QPSO-LSTM 的短期风电负荷预测模型

谭才兴 岳雨霏 汤 赐

(长沙理工大学电气与信息工程学院,湖南 长沙 410114)

**摘要:** 准确的风电预测可以提高电网的稳定性和可靠性,优化风电发电计划,降低能源成本。为了提高短期电力负荷预测的精度,文章探讨了一种基于QPSO算法对LSTM神经网络进行优化的算法,并根据LSTM神经网络以及QPSO算法的基本原理,利用QPSO算法对LSTM的超参数及网络拓扑结构进行优化,建立QPSO-LSTM短期风电负荷预测模型。仿真结果表明,QPSO-LSTM模型较传统的LSTM模型预测精度更高,且具有更快的收敛速度。

**关键词:** 短期风电预测; LSTM神经网络; PSO算法; QPSO算法

**中图分类号:** F407.61

**文献标识码:** A

全球环境问题日益严峻,气候变暖和能源短缺成为亟待解决的全球议题。我国在“十四五”规划中提出要推进能源革命,建设清洁低碳、安全高效的能源体系,加速发展非化石能源,扩大风电、光伏发电规模是有效路径之一<sup>[1]</sup>。截至2021年,我国风电装机规模已连续12年稳居世界首位。其中,2021年,我国陆上风电装机规模突破3亿kW,海上风电装机量跃居世界首位<sup>[2]</sup>。

随着风力发电量在电网中的占比不断上升,对风电并网技术的要求也不断提高<sup>[3]</sup>。风能发电受风速和风向等因素影响较大,具有波动性和间歇性特点,因而风电发电量不稳定。这可能导致系统弃风、失负荷等问题,加剧电力系统的不稳定性和需求供应的不匹配性。因此,对风电负荷进行及时、准确的预测,进而通过电力电子设备的控制和调节,实现对风电场的风能转换、并网和调度,可以改善由于功率不平衡导致的系统稳定性问题,优化电力系统规划和运行。

风电负荷预测可根据时间尺度分为超短期、短期和长期预测,一般分别对应提前0h~4h、提前1d~3d、提前数周或数月<sup>[4]</sup>。本文将利用LSTM神经网络、基于粒子群算法优化的LSTM神经网络、基于量子粒子群算法优化LSTM神经网络三种方法进行短期风电负荷预测,并比较三者的优劣性。

## 1 LSTM神经网络

LSTM是一种特殊的循环神经网络(RNN),用于处理序列数据和时间序列数据。与传统的RNN相比,LSTM具有更强大的记忆能力和长期依赖性建模能力。LSTM的关键思想是引入了一个称为“记忆单元”的结构,用于存储和访问长期记忆。记忆单元由一个称为“细胞状态”的向量组成,可以在时间步长之间传递信息。LSTM还包含输入门、遗忘门和输出门等三个门控单元,用于控制信息流动和更新。

## 2 智能优化算法

### 2.1 粒子群算法

粒子群算法(PSO)是一种基于群体智能的优化算法。PSO通过模拟粒子在搜索空间中的移动和信息交流来寻找最优解。每个粒子代表一个潜在解,并根据自身经验和群体的经验进行位置更新。PSO的基本步骤如下:

(1) 初始化粒子群。随机生成一定数量的粒子,并为每个粒子分配位置和速度。

(2) 评估适应度。根据问题的具体情况,计算每个粒子的适应度值,即目标函数的值。

(3) 更新粒子速度和位置。根据当前的速度和位置,以及全局最优和个体最优的信息,更新每个粒子的速度和位置。

**收稿日期:** 2023-11-03

**基金项目:** 长沙理工大学大学生创新创业训练计划项目“高比例风电电力系统储能运行及配置分析”(2023047);长沙理工大学本科教育“金课”建设项目(线下“金课”)“电机学A”。

**作者简介:** 谭才兴(2003—),男,研究方向为电力系统规划和运行。通讯作者:岳雨霏(1991—),女,讲师,博士,研究方向为电机学、电力电子技术。

(4) 更新全局最优。比较每个粒子的适应度值,更新全局最优的位置。

(5) 重复步骤(3)至(4),直到满足停止条件(如达到最大迭代次数或找到满意的解)。

在每次迭代过程中,粒子的速度更新遵循式(1),粒子的位置更新遵循式(2)。

$$V_{ij} = wV_{ij} + c_1r_{\text{and}}(P_{\text{best},ij} - X_{ij}) + c_2r_{\text{and}}(G_{\text{best},ij} - X_{ij}) \quad (1)$$

$$X_{ij} = X_{ij} + V_{ij} \quad (2)$$

式中,  $V_{ij}$ 表示粒子 $i$ 在第 $j$ 维的速度,  $X_{ij}$ 表示粒子 $i$ 在第 $j$ 维的位置,  $w$ 表示惯性权重,  $c_1$ 和 $c_2$ 分别表示加速度因子,  $P_{\text{best},ij}$ 表示粒子 $i$ 历史上在第 $j$ 维的最优位置,  $G_{\text{best},ij}$ 表示整个粒子群中粒子 $i$ 历史上在第 $j$ 维的最优位置,  $r_{\text{and}}$ 是一个0到1之间的随机数。

## 2.2 量子粒子群算法

量子粒子群算法(QPSO)是指在传统粒子群算法的基础上引入了量子位和量子速度的概念,通过模拟粒子在量子空间中的行为来进行优化,具有量子行为的粒子运行轨迹多变,能有效克服这一缺点<sup>[5]</sup>。

QPSO中粒子群的运动状态是通过一个特殊的波函数来描述<sup>[6]</sup>。波函数的实际意义是粒子出现在某个空间位置的概率。QPSO的运动状态方程可用式(3)至式(6)表示<sup>[7]</sup>。

$$p(t) = \alpha P_i(t) + (1 - \varphi)G_i(t) \quad (3)$$

$$x(t+1) =$$

$$\begin{cases} p(t) + \varphi|m_{\text{best}} - x(t)|(-\ln u), & r \geq 0.5 \\ p(t) - \varphi|m_{\text{best}} - x(t)|(-\ln u), & r < 0.5 \end{cases} \quad (4)$$

$$m_{\text{best}} = \frac{1}{N} \sum_{i=1}^N P_i(t) = \frac{1}{N} \left( \sum_{i=1}^N P_{i1}(t), \sum_{i=1}^N P_{i2}(t), \dots, \sum_{i=1}^N P_{in}(t) \right) \quad (5)$$

$$\varphi = \varphi_{\min} + T \times \frac{\varphi_{\max} - \varphi_{\min}}{T - t} \quad (6)$$

式中,  $x(t+1)$ 表示粒子的当前位置;  $r$ 为区间(0,1)内的随机数;  $x(t)$ 为粒子上一次迭代的位置;  $P_i$ 为第 $i$ 个粒子的个体最优位置;  $G_i$ 为第 $i$ 个粒子的种群最优位置;  $\varphi$ 表示扩张收缩系数,是调节QPSO收敛的关键参数,  $\varphi_{\max}$ 和 $\varphi_{\min}$ 分别为 $\varphi$ 的最大值和最小值,在一般情况下,  $\varphi < 1.781$ ;  $T$ 和 $t$ 代表算法的最大迭代次数和当前迭代次数;  $m_{\text{best}}$ 表示粒子的平均最优位置;  $N$ 表示粒子总数;  $\alpha$ 和 $u$ 为在(0,1)区间随机分布的常数。

## 3 改进的LSTM神经网络

传统的LSTM神经网络超参数和拓扑结构通常是基于经验和试验确定,但这种方法容易受到人为因素的限制,可能无法找到最佳的网络参数。而优化算法能对LSTM神经网络的参数进行训练,确定网络拓扑结构及合适的超参数,以优化网络性能<sup>[8]</sup>。

本文利用PSO算法、QPSO算法对LSTM神经网络的拓扑结构、迭代次数、学习率三个方面进行寻优,确定适合风电负荷数据的最优参数,重新训练LSTM神经网络用于风电预测。

由于PSO-LSTM模型和QPSO-LSTM模型仅在优化算法原理上有所不同,而在模型构建上流程几乎相同。因此本文以QPSO-LSTM模型为例,给出模型构建具体流程如下:

(1) 归一化。为避免某些特征对优化过程的主导作用,使优化更加公平和准确,对搜集的风电负荷数据进行归一化处理,并将处理后的数据分为训练集和测试集。

(2) 初始化模型参数。初始化LSTM神经网络结构和超参数;初始化QPSO粒子群,即种群规模、迭代次数、空间维度及隐藏层节点、学习率和网络迭代次数对应的三种粒子的粒子位置。

(3) 评估适应度。对训练集利用粒子的位置数据作为LSTM神经网络的参数来训练模型,并计算粒子的适应度。本文选取均方根误差RMSE作为适应度函数。

(4) 粒子位置更新。基于适应度值,确定各粒子当前个体的最优解和整个种群的最优解,并利用式(3)至式(6)更新粒子位置。

(5) 重复步骤(3)和(4)直至找到最好的粒子位置或QPSO算法达到最大迭代次数,终止QPSO优化过程。

(6) 将得到的最优粒子代入LSTM训练得到QPSO-LSTM网络模型,并利用模型对测试集样本数据进行预测。若测试集样本预测结果与真实值的RMSE超出给定误差阈值,则返回步骤(2)重新训练模型,直至测试集样本误差小于误差阈值。

QPSO-LSTM模型构建流程图如图1所示。

PSO-LSTM模型的构建流程只需将步骤(4)中粒子位置、速度更新公式替换成式(1)和式(2)即可。

## 4 案例分析

### 4.1 数据来源

本文所用数据来源于中国南部某风电场2020年7月1日至2020年7月15日的风电负荷数据,数据每15 min更

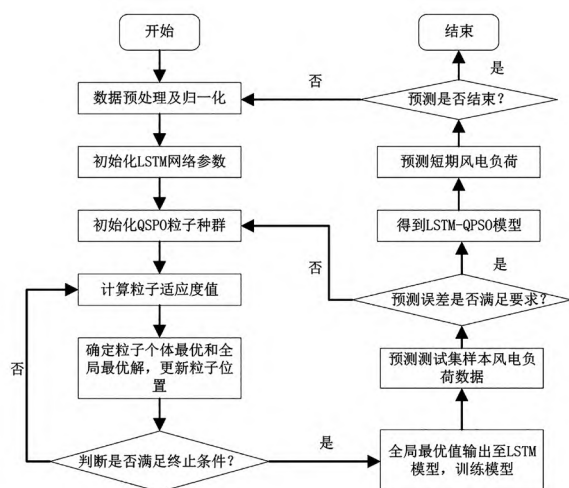


图1 QPSO-LSTM模型构建流程图

新一次,共1 440组。按时间顺序设置训练集和测试集的比例分别为70%和30%,并对数据进行归一化处理。

#### 4.2 模型搭建

对于传统的LSTM预测模型,本文选用前15个样本的风电负荷数据来预测后1个样本的风电负荷。设置其输入、输出以及隐藏层节点数分别为15、1、20,迭代次数为1 000;反向传播算法选用adam算法;激活函数选用tanh函数;采用分段学习率,在训练开始时设置学习率 $l_t$ 为0.005,经过800次迭代后设置学习率 $l_t$ 为0.000 5。

在利用PSO优化LSTM模型参数时,学习率 $l_t$ 取值范围设置为[0.001,0.01],网络训练次数取值范围设置为[10,100],隐藏层节点数 $L_1$ 和 $L_2$ 取值范围设置为[1,200],种群数量为10,迭代次数为1 000。 $N_A, L_1, L_2$ 均为整数。LSTM模型采用固定学习率的方法。QPSO-LSTM模型的参数设置与PSO-LSTM模型相同。

表1 风电预测模型性能对比

预测模型	$R_{MSE}$	$M_{AE}$	$M_{APE}$	$R^2$
LSTM	183.674	136.72	3 220%	0.472 2
PSO-LSTM	82.133 9	55.370 2	2 637%	0.897 2
QPSO-LSTM	81.051 5	54.284 7	1 814%	0.904 4

从表1的计算结果可知,基于PSO和QPSO改进的LSTM神经网络预测精度比传统的LSTM模型有显著提升。而PSO-LSTM与QPSO-LSTM预测精度和拟合度基本相同,以下分析PSO与QPSO算法的收敛速度和效能。

模型种群中粒子的适应度值的大小体现LSTM超参数的好坏。图3为PSO-LSTM模型与QPSO-LSTM模型以归一化后负荷数据的均方根误差作为适应度函数的迭代收敛曲线。适应度越低,模型误差越小,可作为评判模型优劣的指标。

可以看出,PSO-LSTM模型在200次迭代左右后才收敛于局部最优值,而QPSO-LSTM模型在迭代起初就

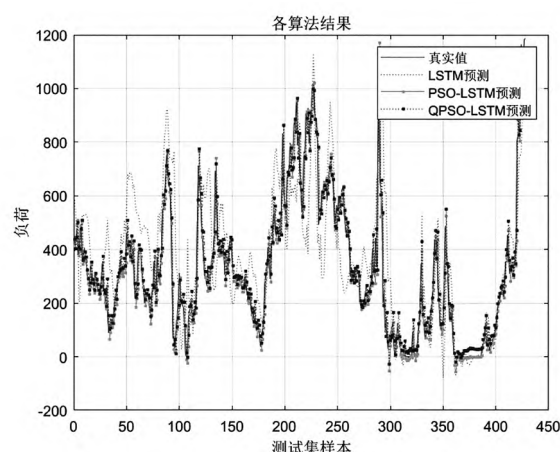


图2 各模型预测效果图

#### 4.3 结果分析

由图2可以看出,在总体上传统的LSTM模型的风电负荷预测的趋势与真实负荷数据大体相同,但预测结果与真实值有较大的误差,特别是当负荷处于波峰、波谷以及负荷剧烈波动的时期,预测精度较小。基于PSO优化的LSTM模型的预测结果与真实值曲线重合度较高,预测精度和拟合度要明显高于传统的LSTM模型,更好地反映了整体负荷趋势;但其在负荷为0附近的拟合效果较差,有少量波谷负荷为负值。而基于QPSO优化的LSTM模型预测的精度和拟合度与PSO-LSTM模型基本相同,但在极点处的拟合度略高于PSO-LSTM模型。

为更加精确体现三种模型的性能对比,计算预测负荷数据与真实负荷数据的均方根误差( $R_{MSE}$ )、平均绝对误差( $M_{AE}$ )、平均绝对百分比误差( $M_{APE}$ )、决定系数( $R^2$ )四种指标如表1所示。

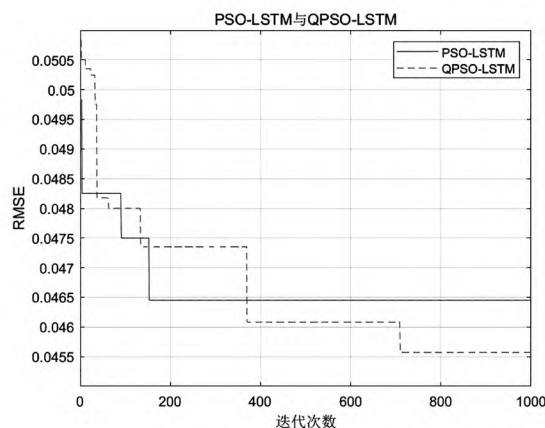


图3 适应度比较



以较快的速度不断更新局部最优值,最终在经过400次迭代后突破了算法限制,避开了局部极值陷阱,并在700次迭代左右找到了全局最优解。由此可知,QPSO-LSTM模型不仅收敛速度快,收敛精度高,而且预测效果好,能够应用于受不确定性、非线性因素影响大的风电负荷预测领域。

## 5 结语

本文提出的QPSO-LSTM风电短期负荷的预测方法能够用于负荷序列属于非平稳、非线性剧烈波动的场景。该方法利用QPSO强大的寻优能力来优化确定LSTM的超参数和网络拓扑结构,进而提高传统LSTM模型的预测效果。同时通过实例分析比较了传统的LSTM模型,PSO-LSTM模型及QPSO-LSTM模型三者的优劣性,算例结果表明基于QPSO-LSTM风电短期负荷预测模型预测精度较高,泛化能力强。

## 参考文献:

[1]杜伟,文腾.《“十四五”现代能源体系规划》

等多项政策出台布局中国新型能源体系[J].国际石油经济,2023,31(1):9-10.

[2]张琛,邓伟.中国风电产业发展现状及趋势研究[J].机电产品开发与创新,2023,36(3):206-208.

[3]王瑾.基于混沌分析和多变量相空间重构的短期风电预测方法研究[D].广州:华南理工大学,2022.

[4]姜雨滋.基于高阶数据变换的风电预测及其在电力系统经济调度中的应用[D].广州:华南理工大学,2022.

[5]范志豪.基于QPSO-BP神经网络的装配式建筑成本预测研究[D].合肥:安徽建筑大学,2022.

[6]宫宇,张莲,杨洪杰,等.基于自适应遗传量子粒子群算法的配电网故障定位[J].浙江电力,2021,40(6):1-7.

[7]宫宇,张莲,李涛,等.量子粒子群算法在配电网恢复重构中的应用[J].重庆理工大学学报(自然科学),2022,36(10):200-207.

[8]蒋子喆.基于改进LSTM混合模型的短期电力负荷预测[D].西安:西安理工大学,2022.

# Study on Short-Term Wind Power Load Forecasting Model Based on QPSO-LSTM

Tan Caixing, Yue Yufei, Tang Ci

(School of Electrical and Information Engineering, Changsha University of Science & Technology, Changsha 410114)

**Abstract:** Accurate wind power forecasting can enhance the stability and reliability of the power grid, optimize wind power generation plans, and reduce energy costs. In order to bolster the accuracy of short-term power load forecasting, the article aims to optimize LSTM neural network through QPSO algorithm. According to the basic principles of LSTM neural network and QPSO algorithm, a forecasting model is established by optimizing the hyperparameters and network topology of LSTM. The simulation results suggest that the QPSO-LSTM model has higher accuracy and faster convergence speed compared to traditional LSTM models.

**Key words:** Short-term wind power forecasting; LSTM neural network; PSO algorithm; QPSO algorithm

(校对:郭雁华 周永康)